

NAGASAKI UNIVERSITY · TPO EXCHANGE PROGRAMME 2026

長崎大学 TPOインターンシップ 2026

Missing Data Theory & Ad-Hoc & Weighted Inference

欠測データ理論とアドホック・重み付け推論手法

A four-week research summary, presented as an exchange student

交換留学生として発表する4週間の研究概要



Madhav Gaur

B.Tech, Computer Science & Applied Mathematics — IIIT-Delhi

July 2026

What This Talk Covers



01

Academic Work

学術研究

Three connected strands of statistical research on missing data and valid inference, completed during the internship.



02

Cultural Experience

文化体験

Reflections from three cities explored during my time in Japan — Tokyo, Osaka, and Kyoto.



PART 1

Academic Work

學術研究

Missing-data theory, ad-hoc deletion, and weighted inference methods - Book Source (Missing Data Analysis and Design)

Three Strands, One Question

「不完全なデータからでも、どうすれば正しい推論ができるか」

How do we draw valid conclusions from data that is incomplete, without silently distorting the variances and relationships hidden inside it?



Missing Data Theory

欠測データ理論

MCAR / MAR / NMAR mechanisms, single imputation, and the case for multiple imputation.



Ad-Hoc & Imputation

アドホック手法と重み付け・代入法

Complete-case, available-case, and weighted analysis, plus the full single-imputation family (mean through PMM) - what each method assumes, and what it costs in bias or variance.



Simulation Verification

シミュレーション検証

Simulated income/spending data test whether textbook bias and variance formulas actually hold.

Why Missing Data Matters

欠測データがなぜ重要なのか

A dataset is rarely perfect. Discarding incomplete rows wastes information; filling them in naively can quietly distort every downstream conclusion.

Means

平均

Variances

分散

Covariances

共分散

Regression Slopes

回帰係数

Standard Errors

標準誤差

p-values

p値

Key Takeaway

Single imputation can distort every one of these quantities at once. The chapter-long lesson: treat imputed values as predictions, never as real observations.

MCAR, MAR, and NMAR

3つの欠測メカニズム — なぜ重要なのか

MCAR

Missing Completely at Random

完全にランダムな欠測

Missingness is unrelated to any value — observed or missing. Complete-case analysis stays unbiased.

MAR

Missing at Random

観測情報で説明できる欠測

Missingness depends only on observed variables. Conditioning on them restores validity.

NMAR

Not Missing at Random

欠測値自体に依存する欠測

Missingness depends on the unobserved value itself, even after conditioning. The hardest case.

Explicit, Implicit & Hybrid Models

統計モデルを選ぶ3つのアプローチ

Explicit

Mean Imputation, Regression Imputation

明示的モデリング

States the statistical model openly: means, regression, Buck's method. Assumptions are visible — but a wrong model gives systematically wrong values.

Implicit

Hot Deck Imputation, Cold Deck Imputation

暗黙的モデリング

Uses an algorithm that implies a model: hot deck, cold deck, substitution. Every algorithm still carries hidden assumptions.

Hybrid

Predictive Mean Matching

予測平均マッチング(ハイブリッド)

Fits a model to define similarity, then imputes an actual donor's value — regression structure with hot-deck realism.

The Full Method Landscape

削除から多重代入までー 学んだ手法のすべて

Four stages, one throughline: every method either discards information, reweights it, or predicts it. Each stage relaxes an assumption the previous stage needed.

01

Complete- & Available-Case

完全・利用可能ケース

Discard incomplete rows, or use every observed value pairwise.

02

Weighting Methods

重み付け手法

Reweight survivors by inverse response probability.

03

Single Imputation

単一代入法

Fill gaps: 10 methods, from a single mean to a matched donor.

04

Multiple Imputation

多重代入法

Impute M times, pool with Rubin's Rules - honest uncertainty.

Complete-Case Analysis

完全ケース分析 — 単純さと引き換えの代償

Restrict the entire analysis to rows with no missing values on any variable used. The default in most software - and the baseline every other method is judged against.

使用するすべての変数に欠測値がない行のみに分析対象を限定する。これは多くのソフトウェアにおける標準的な方法であり、他のすべての手法を評価する際の基準となる。

ADVANTAGE

Simplicity & Comparability

Any standard complete-data method applies unmodified. Every statistic is computed on the same sample base, so cross-tabs stay mutually consistent.

回帰分析やANOVAなどの通常の完全データ手法をそのまま適用できる。すべての統計量が同じサンプルに基づくため、クロス集計の整合性も保たれる。

DISADVANTAGE

Loss of Precision

Discarding rows reduces the effective sample size, increasing variance - even when missingness is completely random (MCAR).

行を削除すると有効サンプルサイズが減少し、欠測が完全にランダムな場合 (MCAR) であっても、分散が大きくなる。

DISADVANTAGE

Bias

If complete cases are not a random subsample (mechanism is not MCAR), CC estimates are biased for the population quantity of interest.

完全ケースがランダムな部分標本でない場合、つまり欠測メカニズムがMCARでない場合、完全ケース分析による推定値は、対象とする母集団の量に対してバイアスを持つ。

Quantifying the Loss of Precision

バイアスがなくても分散が増える理由— Δ_{CC} の定義

Bivariate normal (Y_1, Y_2), monotone missingness: Y_1 observed for all n ; Y_2 observed for r of them. Data are MCAR, so this isolates precision loss from bias.

DEFINITION · $\Delta_{CC} = 1$ means CC needs double the variance of the efficient estimator

$$\text{Var}(\hat{\theta}_{CC}) = \text{Var}(\hat{\theta}_{EFF}) (1 + \Delta_{CC})$$

Mean of Y_1

$$\Delta_{CC} = \frac{n-r}{r}$$

CC discards the $n-r$ rows with Y_2 missing, even though their Y_1 values are perfectly good.
Wasteful - if $r=n/2$, variance doubles.

CCは、 Y_2 が欠測している $n-r$ 行を削除してしまうが、それらの行の Y_1 の値は完全に利用可能である。そのため非効率であり、もし $r=n/2$ なら分散は約2倍になる。

Mean of Y_2

$$\Delta_{CC} \approx \frac{(n-r)\rho^2}{n(1-\rho^2) + r\rho^2}$$

CC loses the $n-r$ rows outright, and fails to use the correlated Y_1 information for them. As $\rho^2 \rightarrow 1$, this converges to $(n-r)/r$.

CCは $n-r$ 行を完全に失い、さらにそれらの行で得られる相関した Y_1 の情報も利用できない。相関が強くなり $\rho^2 \rightarrow 1$ となるにつれて、この損失は $(n-r)/r$ に近づく。

Slope of Y_2 on Y_1

$$\Delta_{CC} = 0$$

Fully efficient. Cases with Y_1 observed but Y_2 missing carry no information about $Y_2|Y_1$ - that relationship is only learned where both are observed.

完全に効率的である。 Y_1 は観測されているが Y_2 が欠測しているケースは、 $Y_2|Y_1$ に関する情報を持たない。この関係は、 Y_1 と Y_2 の両方が観測されているケースからのみ学習される。

Two Proofs Worth Remembering

完全ケース分析における2つの理論的結果

BIAS OF THE CC MEAN

Bias = (missing fraction) ×
(respondent/non-respondent gap)

$$\mu_{CC} - \mu = (1 - p_{CC})(\mu_{CC} - \mu_{IC})$$

CC regression coefficients stay unbiased provided $\Pr(M=1|X,Y) = \Pr(M=1|X)$ — missingness may depend on covariates any way, but not further on Y once X is conditioned upon.

CC回帰係数は、
 $\Pr(M=1|X,Y)=\Pr(M=1|X)\Pr(M=1|X,Y)=\Pr(M=1|X)\Pr(M=1|X,Y)=\Pr(M=1|X)$ が
成り立つ限り不偏である。つまり、欠測は共変量XXXに依存してもよいが、
XXXで条件づけた後にYYYへ追加的に依存してはならない。

Odds Ratio Example

	Increased Blood Pressure		
Caffeine intake "high"?	Yes	No	Total
Yes	130	115	245
No	120	135	255
Total	250	250	500

$$OR = \frac{a \times d}{b \times c} = \frac{130 \times 135}{115 \times 120} = 1.27$$

ODDS-RATIO INVARIANCE

$$OR_{CC} = OR$$

$$\log \Pr(M=1 | Y_1, Y_2) = \alpha + g_1(Y_1) + g_2(Y_2)$$

If response probability factors additively (row effect × column effect, no interaction), the complete-case odds ratio equals the population odds ratio exactly — proof by cancelling the nuisance row/column factors in numerator and denominator.

応答確率が行効果と列効果の積として分解できる場合、つまり交互作用がない場合、完全ケースのオッズ比は母集団のオッズ比と完全に一致する。これは、分子と分母に含まれる不要な行・列の係数が相互に打ち消されることで証明できる。

Fixing Bias With Weights

重み付けクラスと傾向スコア

WEIGHTING CLASS ESTIMATOR

$$w_i = \frac{n_j}{r_j}$$

$$\bar{y}_{wc} = n^{-1} \sum_j n_j \bar{y}_{jR}$$

Unbiased under quasirandomization (MCAR within each class). Each respondent in class j is weighted by sample share n_j over respondent share r_j .

各クラス内で欠測がランダム (MCAR) であれば、不偏である。クラス j の各回答者には、標本内の割合 n_j/n を回答者数 r_j で割った重みが与えられる。

PROPENSITY SCORE SUFFICIENCY

$$M \perp Y \mid p(X)$$

$$p(X) = \Pr(\text{respond} \mid X)$$

Under MAR, propensity weighting works because missingness is assumed to be explained by observed variables. Instead of creating many small weighting classes, we estimate each person's response probability using logistic regression. Using 5–6 propensity groups is more stable.

MARの下では、欠測は観測された変数で説明できると仮定する。ロジスティック回帰で各人の応答確率を推定し、5～6層に分けて用いると安定する。直接重み $w_i = 1/p^*(x_i)$ を使う場合は、モデルの正確さにより強く依存する。

Recovering Data, Risking Coherence

利用可能ケース分析— データを活かすほど整合性が崩れる

RANGE-SAFE PAIRWISE CORRELATION

$$r_{jk} \in [-1, 1]$$

$$r_{jk} = \frac{s_{jk}}{\sqrt{s_{jj} s_{kk}}}$$

All computed on the SAME jointly-observed base I_{jk} . With 20 variables each 10% independently missing, only $0.9^{20} \approx 12\%$ of rows survive complete-case analysis. Available-case analysis uses every observed pair instead — restricting covariance AND variances to the same joint base keeps each correlation individually valid.

すべて同じ共同観測データ I_{jk} に基づいて計算する。20変数がそれぞれ10%欠測すると、完全ケース分析では約 $0.9^{20} \approx 12\%$ の行しか残らない。一方、利用可能ケース分析は観測されている各ペアを用い、共分散と分散を同じ基準で計算するため、各相関は妥当に保たれる。

THE THREE-VARIABLE PARADOX

$$r_{12} = 1, \quad r_{13} = 1, \quad r_{23} = -1$$

$$\{r_{jk}\} \text{ individually valid} \Rightarrow \Sigma \text{ not psd}$$

Each pair is jointly observed on a different subset of rows — no single row observes all three variables together, so nothing anchors the three pairwise estimates to one consistent dataset. Regression needs a positive-definite covariance matrix: this can break downstream analysis entirely.

各ペアは異なる行の部分集合で共同観測されるため3つの変数すべてを同時に観測している共通の行が存在しない。そのため3つのペアごとの推定値を1つの一貫したデータセットに結びつける基準がなくなる。回帰分析には正定値の共分散行列が必要であり、これが崩れると後続の分析全体が成り立たなくなる可能性がある。

Absorbing Bias Into the Weight

重み付き一般化推定方程式 (GEE)

NAIVE COMPLETE-CASE GEE

$$M \perp (Y, Z) \mid X$$

$$\sum_{i \in CC} D_i(x_i, \beta) [y_i - g(x_i, \beta)] = 0$$

Sum over complete cases only. Consistent only if missingness may depend on covariates X already in the mean model, but not on the outcome Y or an auxiliary variable Z (e.g. a symptom linked to dropout).

完全ケースのみを用いて合計する。この方法が一致性を持つのは、欠測が平均モデルに既に含まれる共変量XXXに依存する場合に限られ、結果変数YYYや補助変数ZZZ(例: 脱落に関連する症状)に依存してはならない。

WEIGHTED GEE (ROBINS ET AL., 1995)

$$w_i = 1 / \hat{p}(x, z)$$

$$\sum_{i \in CC} w_i(\hat{\alpha}) D_i(x_i, \beta) [y_i - g(x_i, \beta)] = 0$$

Weighting each complete case by estimated inverse propensity relaxes the condition to: missingness may ALSO depend on Z, provided Z enters the propensity model — algebraically the same cancellation trick as the odds-ratio proof.

推定された逆傾向スコアで各完全ケースに重みを付けることで、条件は緩和される。つまり、補助変数ZZZが傾向スコアモデルに含まれていれば、欠測はZZZにも依存してよい。代数的には、オッズ比の証明と同じように不要な要因が打ち消される。

Mean Imputation: Unconditional vs Conditional

平均値代入 — 全体平均からセル内平均へ

UNCONDITIONAL MEAN

$$Y_i^* = \bar{Y}_{\text{obs}} \text{ for all missing } i$$

$$s_{\text{filled}}^2 = s_{\text{obs}}^2 \frac{n_{\text{obs}} - 1}{n - 1} \approx (1 - \lambda) s_{\text{obs}}^2$$

Every gap gets the same single number, so the completed data are artificially compressed: variance, covariance, and correlation all shrink. Preserves the mean under MCAR, but distorts almost everything else. Generally not recommended.

すべての欠測値に同じ単一の値を入れるため、補完後のデータは人工的に圧縮される。その結果、分散・共分散・相関はいずれも小さくなるMCARの下では平均は保たれるが、それ以外のほとんどの性質を歪めるため、一般的には推奨されない。

CONDITIONAL MEAN (WITHIN CELLS)

$$Y_i^* = \bar{Y}_{hR} \text{ for } i \in h$$

$$\text{Bias}(\bar{Y}_{CM}) = \frac{1}{n} \sum_h m_h (\mu_{hR} - \mu_{hM}); \quad 0 \Leftrightarrow \mu_{hR} = \mu_{hM}$$

Groups units by observed covariates (age × sex × region...), then imputes the respondent mean within each cell. Unbiased once respondents and non-respondents are comparable inside a cell — but still imputes one value per cell, so within-cell variance still shrinks.

観測された共変量(年齢×性別×地域など)に基づいて単位をグループ化し、各セル内の回答者平均で欠測値を補完する。セル内で回答者と非回答者が比較可能であれば不偏となるが、各セルに同じ値を補完するため、セル内分散は依然として小さくなる。

Regression Imputation & Buck's Method

回帰代入からバック法へー 共分散行列を使った一般化

REGRESSION IMPUTATION

$$\hat{Y}_i = X_i \hat{\beta}$$

$$Y_i = X_i \beta + \varepsilon_i \Rightarrow Y_i^* = X_i \hat{\beta} \quad (\varepsilon_i \text{ discarded})$$

Generalizes conditional-mean imputation to continuous covariates. But every imputed point sits exactly on the regression line — real data scatter around it — so residual variance is systematically underestimated.

条件付き平均補完を連続共変量にも拡張した方法である。しかし、補完された値はすべて回帰直線上に置かれるため、実際のデータに存在するばらつきが失われる。その結果、残差分散は体系的に過小評価される。

BUCK'S METHOD (GENERAL PATTERNS)

$$Y_{\text{mis}}^* = \hat{\mu}_{\text{mis}} + \hat{\Sigma}_{mo} \hat{\Sigma}_{oo}^{-1} (Y_{\text{obs}} - \hat{\mu}_{\text{obs}})$$

$$E(s_{jj, \text{Buck}}) \approx \sigma_{jj} - \frac{1}{n} \sum_i \sigma_{jj | \text{obs}, i}$$

Extends regression imputation to ANY missing-data pattern at once, using one complete-case mean vector and covariance matrix — reused per pattern via the sweep operator, not refit per row. Efficient, but still a conditional-mean method underneath.

任意の欠測パターンに対して一括で回帰補完を拡張する方法である。完全ケースから得た1つの平均ベクトルと共分散行列を用い、各欠測パターンに対してスweep演算子で再利用するため、行ごとに再推定する必要がない。効率的ではあるが、本質的には条件付き平均補完である。

From a Mean to a Draw

確率的回帰代入 — 平均ではなく「もっともらしい値」を引く

Mean-based imputations (unconditional, conditional, regression, Buck's) all fill the center of a predictive distribution. Real missing values scatter around that center.

FORMULA

$$Y_i^* = X_i \hat{\beta} + z_i, \quad z_i \sim N(0, \hat{\sigma}_{\text{res}}^2)$$

KEY TAKEAWAY

Regression gives the conditional mean. Stochastic regression gives a conditional draw.

Adding random residual noise restores realistic variability. For binary outcomes the same idea gives $Y_i^* \sim \text{Bernoulli}(\hat{p}_i)$ instead of rounding a probability.

回帰補完は条件付き平均を与える。一方、確率的回帰補完は条件付き分布から値を抽出する。ランダムな残差ノイズを加えることで、現実的なばらつきを回復できる。二値アウトカムの場合も同様に、確率を丸めるのではなく、 $Y_i^* \sim \text{Bernoulli}(p_i)$ $Y_i^* \sim \text{Bernoulli}(\hat{p}_i)$ $Y_i^* \sim \text{Bernoulli}(p_i)$ として補完する。

WHY IT MATTERS

This is the pivot point of the entire chapter.

Every method after this slide — hot deck, PMM, multiple imputation — is some version of 'impute a draw, not a mean'. The four-method comparison on the next slide proves it formally.

これは章全体の転換点である。このスライド以降の手法、つまりホットデック、PMM、多重代入はすべて「平均ではなく、分布から値を抽出して補完する」という考え方に基づいている。次のスライドの手法比較は、この点を形式的に示している。

Umean, Udraw, Cmean, Cdraw

二変量正規分布における4手法の比較 — バイアスの数式

Umean • Unconditional

$$\text{Bias}(\sigma_{22}) = -\lambda\sigma_{22}$$

Ignores Y1 entirely. Preserves the mean, destroys variance and the regression relationship.

Udraw • Marginal Draw

$$\text{Bias}(\beta_{12}) \neq 0$$

Preserves marginal variance of Y2, but damages the Y1–Y2 relationship since it ignores Y1.

Cmean • Conditional

$$\text{Bias}(\sigma_{22}) = -\lambda(1-\rho^2)\sigma_{22}$$

Keeps the regression slope, but residual scatter is still missing — variance still shrinks.

Cdraw • Conditional Draw

$$\text{Bias} = 0 \quad \forall \mu, \sigma_{22}, \beta_{21}, \beta_{12}$$

The only method among all four with zero bias across every listed parameter — proof that draws beat means once you also condition on what you know.

Efficiency Tradeoff

$$+\frac{\lambda(1-\lambda)(1-\rho^2)\sigma_{22}}{n}$$

Cdraw's only cost: extra sampling variance on the mean. Realism has a small, honest price.

Hot Deck: Copying a Real Respondent

ホットデッキ法 — 平均ではなく実在する値をコピーする

SIMPLE RANDOM HOT DECK

$$Y_i^* = Y_J, \quad J \sim \text{Unif}(\text{respondents})$$

$$\text{Var}(\bar{Y}_{HD1}) = \left(\frac{1}{r} - \frac{1}{N}\right) S_y^2 + \left(1 - \frac{1}{r}\right) \left(1 - \frac{r}{n}\right) \frac{S_y^2}{n}$$

$E(\bar{Y}_{HD1}) = \bar{Y}$ under MCAR — unbiased. The second variance term is an honest extra cost of donor sampling: donor counts $(H_1, \dots, H_r)$ follow a Multinomial($n-r$; $1/r, \dots, 1/r$).

HOT DECK WITHIN ADJUSTMENT CELLS

$$Y_i^* = Y_J, \quad J \in D_i = \{j : R_j = 1, j \in h\}$$

$$E(Y_i^* \mid Y_{\text{obs}}) = \bar{Y}_{hR}$$

Matches cell-mean imputation in expectation — but every imputed value is a real observed value, so realistic scatter survives instead of being flattened to an average.

期待値ではセル平均補完と一致する。しかし、補完値はすべて実際に観測された値であるため、平均に平坦化されるのではなく、現実的なばらつきが維持される。

Nearest-Neighbor (KNN) Hot Deck

最近傍法ホットデックー 距離に基づくドナー選択

Donors are selected from the nearest respondents in covariate space, using a distance $d(i,j)$.

DISTANCE METRICS

Mahalanobis & Predictive-Mean Distance

$$d(i, j) = (X_i - X_j)^T S_{XX}^{-1} (X_i - X_j)$$

$$d(i, j) = [\hat{Y}(X_i) - \hat{Y}(X_j)]^2$$

Other options include maximum-deviation and plain Euclidean distance.

その他の選択肢として、最大偏差距離や通常のユークリッド距離がある。

THE SCALING PROBLEM

Large-scale variables silently dominate

Example: income spans 0 to 2,000,000 while age spans 18 to 80. Raw Euclidean distance mostly measures income, not age.

$$Z = \frac{X - \bar{X}}{s_X}$$

Standardize first, or use domain weights, anchor groups, Mahalanobis distance, or predictive mean matching instead.

Sequential Hot Deck

順序型ホットデックー アンカーグループと並べ替え

Form an exact-match anchor group A_i (e.g. region $\times$ industry), sort records inside it by a variable related to the missing value, then choose a nearby donor in that sorted order.

DONOR WINDOW

$$D_i(L) = \{ j : R_j = 1, A_j = A_i, |\text{rank}(j) - \text{rank}(i)| \leq L \}$$

REAL EXAMPLE: CONSTRUCTION SURVEY

Anchors + sort + distance

Post-strata by province $\times$ SIC $\times$ SWI; sort within each by gross business income; take the nearest 5 donors either side; distance $d(i,j) = |\ln(\text{TEXP}_i) - \ln(\text{TEXP}_j)|$. A usage penalty $d^* = d + \gamma u_j$ stops one donor from being reused too often.

州 $\times$ SIC $\times$ SWI によって事後層化し、各層内で総事業収入の順に並べる。各対象について前後5人ずつの最も近いドナーを選ぶ。距離は $d(i,j) = |\ln(\text{TEXP}_i) - \ln(\text{TEXP}_j)|$ と定義する。使用ペナルティ $d^* = d + \gamma u_j$ を加えることで、同じドナーが過度に再利用されるのを防ぐ。

EDIT CONSTRAINTS

Respecting logical totals

If $x+y \leq z$ must hold and candidate i has z_i but not x_i, y_i , copy the donor's PATTERN, not its raw values: $x^*_i = (x_j/z_j)z_i$, $y^*_i = (y_j/z_j)z_i$ — transfers shape while respecting the candidate's own total.

$x+y \leq z$ が成り立つ必要があり、対象 iii には z_i はあるが x_i, y_i が欠測している場合、ドナーの生の値ではなく「比率パターン」をコピーする。すなわち、 $x_i^* = (x_j/z_j)z_i$, $y_i^* = (y_j/z_j)z_i$ とする。これにより、対象自身の合計値を保ちながら、ドナーの構成比を移すことができる。

Cold Deck Imputation

コールドデッキ法ー 外部・過去のデータを使う

FORMULA & BIAS ・ unbiased iff $C(X_i) = m_M(X_i)$

$$Y_{CD,i} = R_i Y_i + (1 - R_i) C(X_i); \quad \text{Bias}(\bar{Y}_{CD}) \approx \frac{1}{n} \sum_i [C(X_i) - m_M(X_i)]$$

Feature	Sequential Hot Deck	Cold Deck
Source	Current sample donors	External / old source
Value copied	Actual current respondent value	Lookup / historical value
Adapts to current sample	Yes	Often weakly
Main risk	Bad matching or donor overuse	External value is wrong or outdated
Uncertainty	Still understated in single imputation	Often severely understated

Predictive Mean Matching (PMM)

予測平均マッチングー 回帰とホットデックの融合

A model defines similarity; an actual observed value gets imputed. The hybrid that bridges explicit and implicit modeling.

1

Fit a model

$\hat{Y} = \hat{m}(X)$ using observed cases only.

2

Predict for everyone

Compute $\hat{m}(X)$ for both observed and missing cases.

3

Find close matches

For missing case i , find observed j with small $|\hat{m}(X_i) - \hat{m}(X_j)|$.

4

Draw a donor

Randomly choose one donor from the closest candidates — not just the nearest.

5

Impute the real value

$Y^*_i = Y_j$ — the donor's actual observed value, never a predicted number.

KEY TAKEAWAY

PMM uses a model to define similarity but still imputes an actual observed value — regression structure with hot-deck realism, and no distributional assumption on the residual.

Mathematical Proof, or Empirical Claim?

どこまでが数式で証明され、どこからが経験則か

Most of these bias/variance claims are formal results under stated assumptions, not simulation folklore - except where the donor-selection algorithm is too complex for closed form.

Method	Mathematical Claim	Nature of Claim
Unconditional mean	Variance/covariance attenuation factor $(n_{\text{obs}}-1)/(n-1)$	Formal under MCAR
Conditional cell mean	Bias = weighted respondent/non-respondent gap inside cells	Formal decomposition
Regression imputation	Removes residual variance by construction (imputes conditional mean)	Model-based
Buck's method	Variance/covariance underestimated by residual conditional-variance terms	Formal under assumptions
Cdraw (bivariate normal)	Bias exactly zero for μ , σ_{22} , β_{21} , β_{12}	Formal, worked example
Simple random hot deck	Donor counts $\sim$ Multinomial; closed-form variance available	Formal
Sequential / KNN hot deck	Bias depends on matching quality and distance rule chosen	Less complete theory
Cold deck	Bias depends entirely on correctness of the external source	Obvious, but source-dependent

Testing the Theory Against Real Numbers

理論を実際のシミュレーションデータで検証する

DESIGN

Six missingness scenarios, one linear model

A single regression $Y \sim X$ is estimated after inducing $\sim 30\%$ missingness in one variable at a time, under all three mechanisms: MCAR, MAR (driven by a measured covariate Z or by the other variable), and MNAR (driven by the variable's own unobserved value).

約30%の欠測を1つの変数に順番に発生させた後、単一の回帰モデル $Y \sim X$ を推定する。欠測メカニズムは3種類すべてを扱う: MCAR、MAR (観測された共変量 Z またはもう一方の変数に依存)、MNAR (その変数自身の未観測値に依存)。

METHODS COMPARED


Complete case · Mean · Regression/iterative · Multiple imputation

Every scenario is run through all four methods and compared against the known true $\beta = 1.10$, recording $\hat{\beta}$, Bias = $\hat{\beta} - \beta$, and the standard error - exactly the quantities the theory chapters make formal predictions about.

各シナリオを4つすべての手法で実行し、既知の真の値 $\beta = 1.10$ と比較する。記録するのは、 $\hat{\beta}$ 、バイアス $= \hat{\beta} - \beta$ 、および標準誤差であり、理論章が形式的に予測する量と対応している。

Bias by Method: Y Is Missing

従属変数Yが欠測している場合のバイアス比較




READING THE CHART

Mean imputation's bias explodes as the mechanism worsens ($-0.34 \rightarrow -0.41 \rightarrow -0.56$). Multiple imputation tracks the theory's prediction closely and stays smallest or near-smallest throughout.

Bias by Method: X Is Missing

説明変数Xが欠測している場合のバイアス比較




A COUNTERINTUITIVE RESULT

Regression/iterative imputation - the strongest method for Y-missing - becomes the WORST here (+0.21 to +0.26 bias). Imputing a predictor from itself manufactures correlation that was not there.

Variance Preservation by Imputation Method

各補完手法における分散保存の比較



READING THE CHART

Unconditional and conditional mean imputation severely underestimate variance (ratio drops to ~0.6). Hot deck (simple, KNN) and stochastic regression preserve the natural variance perfectly (ratio ~ 1.0).

KNN-Based Imputation

KNNホットデッキ法による欠測値補完のプロセス

DONOR SELECTION PROCESS

1. Identify Missing Case

The target record containing the missing value is designated as the recipient (red X).

2. Distance Metric Calculation

Standardized numeric variables and one-hot encoded categorical distances are computed to find similar cases.


3. Pool K Nearest Neighbors

The closest matching donor candidates (orange circles) are identified within the observed pool.

4. Impute from Chosen Donor

A final donor (green star) is selected from the candidate pool to fill the missing value.

KNN Hot Deck Donor Example under MCAR
Actual KNN uses standardized numeric + one-hot categorical distance



Key Empirical Findings

実験からわかった3つの教訓

FINDING 1

Mean imputation is unsafe under any mechanism

Bias worsens monotonically from MCAR (-0.34) to MNAR (-0.56) when Y is missing - exactly the attenuation the textbook formula $(1-\lambda)s^2_{\text{obs}}$ predicts, at real magnitude.

Y が欠測している場合、バイアスはMCAR (-0.34) から MNAR (-0.56) へ単調に悪化する。これは、教科書の式 $(1-\lambda)s^2_{\text{obs}}$ が予測する減衰を、実際の大きさを示している。

FINDING 2

Imputing a predictor is not symmetric with imputing an outcome

Regression imputation excels for Y -missing but is the single worst method for X -missing - it manufactures a correlation between X and its own predictors that inflates β .

回帰補完は Y が欠測している場合には優れているが、 X が欠測している場合には最も悪い方法となる。これは、 X とその予測変数との間に人工的な相関を作り出し、 $\hat{\beta}$ を過大評価してしまうためである。

FINDING 3

Multiple imputation is the most consistently reliable

Smallest or near-smallest $|\text{bias}|$ in 5 of 6 scenarios, with SE of comparable size to the other methods - confirming Rubin's Rules honestly price in imputation uncertainty without overcorrecting.

6つのシナリオのうち5つで、バイアスの絶対値が最小またはそれに近く、標準誤差も他の手法と同程度であった。これは、Rubinのルールが過剰に補正することなく、補完による不確実性を適切に反映していることを示している。



PART 2

Cultural Experience

文化体験

Three cities that shaped my time in Japan as an exchange student



PART 2 · CULTURAL EXPERIENCE

Tokyo - The Capital and Chaos

東京

東京滞在中に、浅草、秋葉原、銀座、上野、新宿、渋谷を訪れる機会がありました。街の活気や賑わいは、言葉では十分に表すことができません。一日を通して多くのことが同時に起こっており、これほど多くの観光客が集まっている様子を見るのも初めてでした。

これまで訪れた国々の中でも、東京の公共インフラは特に優れていると感じました。特に、地下鉄やR線を含む広範な鉄道網には大変感銘を受けました。また、新幹線に乗車する機会にも恵まれ、私にとって非常に思い出深い経験となりました。



PART 2 · CULTURAL EXPERIENCE

Osaka - Hidden Japan, Mini Tokyo

大阪

大阪は、活気、温かさ、そして賑やかさに満ちた、日本のまた違った一面を表していました。京都の伝統的な雰囲気や、東京の速く整った都市の姿とは異なり、大阪はより親しみやすく、表現豊かで、人とのつながりを感じられる街でした。特に道頓堀周辺の賑やかな通りは、大阪の有名な食文化と明るい雰囲気をよく表していました。交換留学生として、大阪では食べ物、会話、ユーモア、そして人々の日常的な温かさを通して、日本のより気さくで活気ある文化を感じることができました。



PART 2 · CULTURAL EXPERIENCE

Kyoto - Where the Past meets the Present

京都

京都は、日本の真の文化的中心地を象徴しており、過去と現在が美しく融合している場所でした。特に伏見稲荷大社をはじめとする神社は本当に素晴らしく、その伝統的な建築は、東京や大阪の近代的な景観とははっきりと対照的でした。交換留学生として、私は日本の礼儀作法や社会的な規律を間近で感じることができました。特に、人々が優雅に規則を守る姿や、お辞儀の文化に表れる深い敬意がとても印象的でした。

Exchange Journey Gallery

思い出のアルバム · A visual record of cities, culture, and connections



Tokyo 東京



Osaka 大阪



Kyoto 京都



Cultural Experiences
文化体験

Thank You / ありがとうございます



Nagasaki University

長崎大学

For hosting the TPP Internship 2026 and this research placement.



Prof. Yuta Umezu

ユウタ・ウメズ教授

For supervision of my Exchange Research at Nagasaki University.



Hiromi Collins Sensei

コリンズ・ヒロミ先生

For seamless integration and guidance regarding daily activities and Japanese language

Questions are welcome — 質問を歓迎します
GitHub Link — [MadhavGaur123/Nagasaki-University-](https://github.com/MadhavGaur123/Nagasaki-University-)